Affinage de modèles génératifs pour l'inférence en langue naturelle pour les essais cliniques : XXXX et YYYYY

Prénom1 Nom1[1, 2] Prénom2 Nom2[1, 3]
Université-Paris-Saclay, CNRS, Laboratoire Interdisciplinaire des Sciences du Numérique
utrucmuche@lab.fr, umachinchose@adresse-academique.be

RÉSUMÉ
Les Grands Modèles de Langage ont démontré des résultats compétitifs pour de nombreuses applications, y compris dans des domaines de spécialité comme le domaine biomédical.

ABSTRACT
Here the title in English.

Here an abstract in English (max. 150 words).

MOTS-CLÉS : Inférence en langue naturelle, Grands Modèles de Langage, essais cliniques, affinage, apprentissage avec peu d'exemples.

KEYWORDS: Natural language inference, Large Language Models, clinical trials, finetuning, few-shot learning.

1 Introduction

2 Travaux connexes

Ici on met les travaux précédemment publiés dans la littérature.

3 Méthodes

3.1 Préparation des données NLI4PR

Notre jeu de données présente (NLI4PR) une spécificité majeure : pour chaque patient, nous disposons de deux descriptions équivalentes sur le plan clinique, mais formulées différemment. La première est rédigée dans un langage médical technique (destiné aux professionnels), tandis que la seconde est formulée dans un langage courant (langage patient).

Afin d'optimiser les temps de calcul et de s'adapter aux contraintes de ressources matérielles, la phase de *fine-tuning* n'a pas été réalisée sur l'intégralité des données. Nous avons opté pour un échantillonnage aléatoire consistant à extraire 50 % du jeu d'entraînement rédigé en langage médical et 50 % de celui en langage patient. Ces deux sous-ensembles ont ensuite été fusionnés et mélangés

aléatoirement (*seed* fixée à 42 pour la reproductibilité) afin d'exposer le modèle aux deux registres de vocabulaire lors de son apprentissage. La phase d'évaluation finale a, quant à elle, été menée de manière exhaustive sur les deux ensembles de test séparément, permettant ainsi une analyse comparative détaillée des performances selon le type de langage.

3.2 Structure et stratégies de Prompting NLI4PR

Pour interroger le modèle, trois stratégies de formatage des requêtes (*prompts*) ont été mises en œuvre et comparées :

- **Standard NLI Prompt :** Cette approche classique de *Natural Language Inference* (NLI) sépare le texte en deux blocs distincts : une `Premise` (contenant les critères d'inclusion et d'exclusion de l'essai) et une `Hypothesis` (contenant la description du patient). Le modèle reçoit pour instruction système stricte de classer la relation en répondant uniquement par « Entailment » (Éligible) ou « Contradiction » (Non-éligible).
- **Clinical Matching :** Cette stratégie reformule la tâche NLI sous la forme d'une question clinique directe et naturelle. Le prompt est structuré ainsi : *« Does the patient with the statement [Description du patient] satisfy the following clinical trial admission criteria ? [Critères] »*. L'instruction impose toujours une réponse en un seul mot.
- **Chain of Thought (CoT) Prompt :** Reposant sur la même structure que le Clinical Matching, cette approche intègre une consigne poussant le modèle à expliciter son raisonnement avant de conclure. L'instruction ajoutée est la suivante : *« First, explain your reasoning step-by-step by comparing the patient's characteristics to the inclusion and exclusion criteria. Then, conclude on a new line with only one word : 'Entailment' or 'Contradiction' »*.

3.3 Configuration du modèle et Fine-tuning (NLI4PR et NLI4CT)

Le modèle de base sélectionné pour nos expériences est **Qwen 2.5 7B Instruct** (`Qwen2.5-7B-Instruct`), reconnu pour ses excellentes capacités de raisonnement et de suivi d'instructions. Cette même configuration est utilisée pour les deux jeux de données (NLI4PR et NLI4CT).

Pour rendre l'entraînement réalisable efficacement, nous avons appliqué une méthode d'optimisation paramétrique efficace (PEFT) basée sur **LoRA** (Low-Rank Adaptation). Les hyperparamètres LoRA ont été configurés avec un rang $r = 16$, un *alpha* de 32, et un *dropout* de 0.05. L'adaptation a été ciblée sur l'ensemble des modules de projection de l'architecture *Transformer* (`q_proj`, `k_proj`, `v_proj`, `o_proj`, `gate_proj`, `up_proj`, `down_proj`). De plus, le modèle de base a été quantifié en 4-bit via `bitsandbytes` (format *nf4* avec double quantification) pour réduire l'empreinte mémoire, en utilisant la précision `bfloat16` pour les calculs.

L'entraînement a été réalisé à l'aide de la bibliothèque `trl` (*SFTTrainer*). Pour NLI4PR, le nombre d'époques a été fixé à 4 afin de limiter le temps de calcul ; pour NLI4CT, l'affinage a été conduit sur 5 époques. La taille de lot (*batch size*) a été fixée à 2 par dispositif avec 4 étapes d'accumulation de gradient (*gradient accumulation steps*). Le taux d'apprentissage (*learning rate*) était de 2×10^{-4}. La longueur maximale de séquence a été fixée à 4096 *tokens* afin d'éviter toute troncature des descriptions cliniques les plus longues, et le *gradient checkpointing* a été activé pour optimiser l'usage de la mémoire.

3.4 Stratégies d'Évaluation et Inférence NLI4PR

Pour garantir la robustesse des métriques d'évaluation (*Accuracy*, *F1-score*), des stratégies de traitement des réponses (*parsing*) spécifiques ont été développées selon la stratégie de *prompting* utilisée. Lors de toutes les inférences, la température a été fixée à 0.7 avec un *top-p* de 1.0.

Évaluation des prompts NLI et Clinical Matching NLI4PR Dans ces configurations, le modèle est instruit pour répondre par un mot unique. Par conséquent, la génération a été bridée à un maximum de 10 *tokens* (`max_new_tokens=10`). Bien que la consigne soit stricte, les LLMs peuvent occasionnellement générer des espaces initiaux ou des signes de ponctuation. Notre algorithme d'évaluation convertit la réponse en minuscules et recherche la présence des racines `entail` ou `contradict` dans les 50 premiers caractères générés. Si les mots-clés sont identifiés, la prédiction est catégorisée en conséquence ; sinon, le texte brut est retourné pour vérification manuelle.

Évaluation du prompt Chain of Thought (CoT) NLI4PR Contrairement aux approches précédentes, le modèle génère ici un texte explicatif complet. La limite de génération a donc été étendue à 1024 *tokens* (`max_new_tokens=1024`). Le mot-clé déterminant la prédiction se trouvant à la fin du raisonnement, la méthode d'extraction employée découpe la réponse générée par sauts de ligne, isole la dernière ligne non vide, et y recherche les mots-clés de classification. En cas d'absence de saut de ligne (non-respect occasionnel de la consigne), une méthode de secours inspecte l'intégralité du texte. Cette approche garantit une classification automatisée fiable tout en conservant le texte du raisonnement pour une analyse ultérieure.

3.5 Préparation des données NLI4CT

Le jeu de données NLI4CT (*Natural Language Inference for Clinical Trials*) repose sur des protocoles d'essais cliniques : pour chaque instance, une **prémisse** est constituée par l'extraction de critères ou d'informations depuis des sections structurées des protocoles (Eligibility, Intervention, Adverse Events, etc.), et une **hypothèse** (*Statement*) décrit une affirmation à évaluer au regard de cette prémisse. Le label est binaire : `Entailment` (l'affirmation est supportée par les critères) ou `Contradiction`. Deux types de tâches sont représentés : **Single** (un seul essai de référence) et **Comparison** (comparaison entre un essai primaire et un essai secondaire), ce qui permet d'évaluer à la fois l'éligibilité simple et le raisonnement comparatif. Les données sont issues des fichiers `train.json`, `dev.json` et d'un ensemble `Gold_test.json` (500 exemples) utilisé pour l'évaluation finale. Les preuves sont extraites depuis des fichiers JSON par essai (`CT_json`) en fonction des indices de preuve associés à chaque entrée.

3.6 Structure et stratégies de Prompting NLI4CT

Pour NLI4CT, deux formats de prompt ont été comparés, en cohérence avec une formulation NLI classique prémisse/hypothèse :

— **Prompt 1 (NLI standard) :** Le message système demande de classer la relation entre la prémisse et l'hypothèse en répondant par un seul mot (`Entailment` ou `Contradiction`).

Le contenu utilisateur est structuré en deux blocs : `PREMISE:` (contenant les critères ou extraits de protocole) et `HYPOTHESIS:` (l'énoncé à évaluer).

— **Prompt 2 (question explicite) :** La même structure prémisse/hypothèse est conservée, avec une formulation interrogative explicite : *« Is this premise in agreement with the following hypothesis ? »* suivie de l'hypothèse, et une consigne de réponse en un mot.

Pour chaque prompt, un modèle **baseline** (sans affinage) et un modèle **affiné** (fine-tuné sur les données d'entraînement NLI4CT au format correspondant) sont évalués sur le Gold test.

3.7 Few-shot et évaluation NLI4CT

En complément du fine-tuning, trois stratégies **few-shot** ont été appliquées sur NLI4CT avec le format Prompt 1. Dans les trois cas, chaque requête de test est précédée de deux exemples (un `Entailment` et un `Contradiction`) ; seule la méthode de sélection des exemples diffère :

— **Sélection par type et section :** les exemples sont choisis dans le jeu d'entraînement en croisant le *type* de tâche (Single ou Comparison) et l'identifiant de *section* (Eligibility, Intervention, etc.) de l'instance de test. Pour chaque couple (type, section), on retient un exemple de chaque label, ce qui assure une cohérence métier avec la requête.

— **KATE** (kNN-Augmented in-context Example selection) : pour chaque instance de test, on calcule des représentations sémantiques (embeddings RoBERTa) des paires prémisse/hypothèse du jeu d'entraînement, puis on retient les exemples les plus proches en similarité cosine pour chaque label. La sélection est donc purement sémantique, indépendante du type ou de la section.

— **Similarité cosine (sentence-transformers) :** une variante sémantique utilisant un modèle *sentence-transformers* pour encoder les paires ; on retient à nouveau, pour chaque label, les exemples d'entraînement les plus proches en similarité cosine de l'instance de test.

Le message système few-shot précise que le modèle doit s'inspirer des exemples puis classer la dernière paire en un mot. L'évaluation repose sur le même principe de *parsing* que pour NLI4PR : recherche des racines `entail` ou `contradict` dans la sortie générée (limite de 10 *tokens*), avec température 0,7 et *top-p* 1,0. Les résultats des trois stratégies few-shot sont comparés aux modèles baseline et fine-tunés (Prompt 1 et Prompt 2) pour analyser la complémentarité des approches.

4 Résultats

4.1 Résultats NLI4CT

L'évaluation porte sur le Gold test NLI4CT. Les métriques (exactitude et macro F1) des cinq approches sont synthétisées dans le tableau 1, mais nous analysons principalement le macro F1, plus informatif en cas de déséquilibre entre classes.

Deux configurations de fine-tuning. Le fine-tuning améliore nettement les modèles sans affinage pour les deux formats de prompt en termes de macro F1. Le Prompt 1 affiné atteint un macro F1 de 75,3 % (contre 64,8 % pour le modèle sans affinage correspondant), le Prompt 2 affiné atteint 72,8 % (contre 64,2 % pour le modèle sans affinage correspondant). Le Prompt 1 reste donc le plus performant après affinage. Les figures 1 et 2 donnent les macro F1 des deux modèles fine-tunés en

TABLE 1 – Précision (accuracy) et macro F1 — NLI4CT.

Approche	Exactitude (%)	Macro F1 (%)
P1 Baseline	65,8	64,8
P1 Fine-tuné	**74,2**	**75,3**
P2 Baseline	65,2	64,2
P2 Fine-tuné	71,8	72,8
Few-shot (type+section)	72,0	71,7
Few-shot KATE	71,4	71,2
Few-shot Cosine	71,0	70,9

fonction du type de tâche (Single vs Comparison) et de la section de protocole : les deux modèles affinés ont de meilleurs résultats que les modèles sans affinage dans la plupart des sous-groupes, avec des écarts selon la section. On observe en particulier que la tâche est un peu plus simple sur la section Adverse Events (macro F1 plus élevé) que sur la section Eligibility ; il y a une différence visible entre la tâche la plus simple (Adverse Events) et la plus difficile (Eligibility).

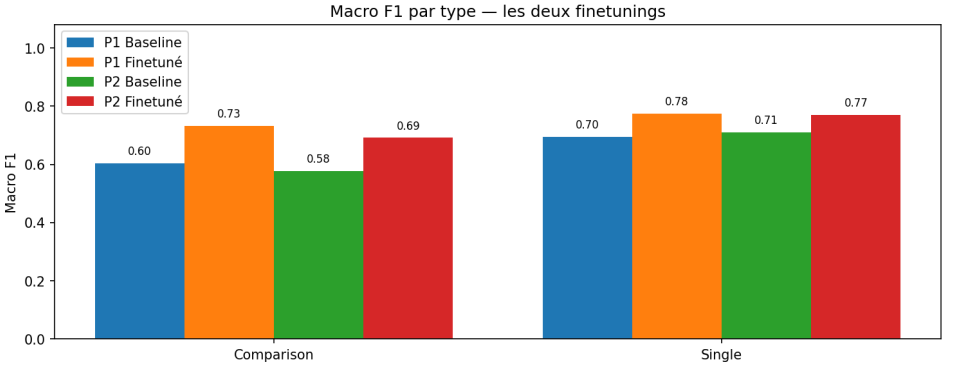

FIGURE 1 – Macro F1 par type de tâche (Single / Comparison) pour les modèles sans affinage et modèles fine-tunés (Prompt 1 et Prompt 2).

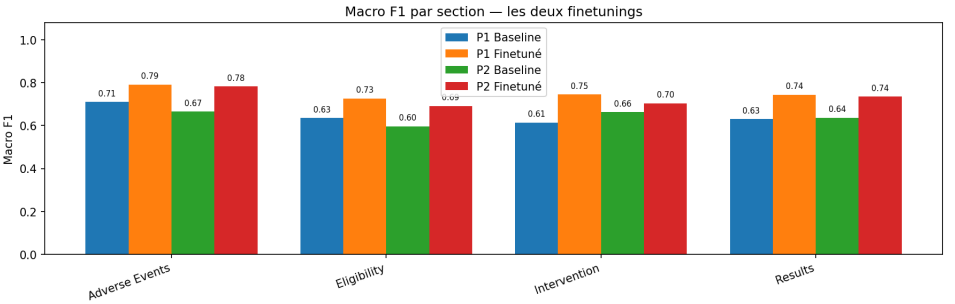

FIGURE 2 – Macro F1 par section de protocole pour les modèles sans affinage et modèles fine-tunés.

Par ailleurs, le fine-tuning introduit des régressions (exemples corrects avec le modèle sans affinage, erronés après affinage) et des améliorations (erronés avec le modèle sans affinage, corrects après affinage) : pour le Prompt 1 on observe 60 régressions et 102 améliorations ; pour le Prompt 2, 60 régressions et 93 améliorations. Le bilan net reste positif pour les deux prompts. Une explication probable des régressions est que les modèles sans affinage prédissent en majorité la classe Contradiction : lorsqu'une prédiction correcte du modèle sans affinage était « contradiction », l'affinage peut parfois faire basculer le modèle vers « entailment » et ainsi créer une régression. Les quatre matrices de confusion (P1 Baseline, P1 Fine-tuné, P2 Baseline, P2 Fine-tuné) reportées en figure 3 illustrent ce déséquilibre des modèles sans affinage vers la contradiction et le rééquilibrage apporté par le fine-tuning.

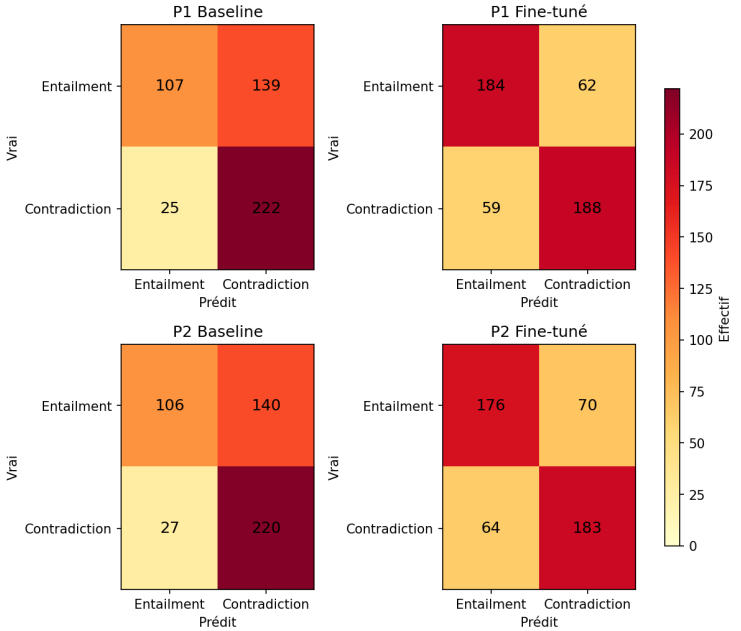

FIGURE 3 – Matrices de confusion pour P1 Baseline, P1 Fine-tuné, P2 Baseline et P2 Fine-tuné. Les modèles sans affinage tendent à prédire majoritairement Contradiction ; le fine-tuning rééquilibre les prédictions, ce qui peut expliquer une partie des régressions (exemples où une prédiction correcte en contradiction du modèle sans affinage devient erronée après affinage).

L'analyse par longueur de prompt est donnée en figures 4 et 5. Les données ont été découpées en sous-ensembles (*bins*) de la façon suivante : pour la figure 4, la longueur du prompt (en tokens) est partagée en terciles (quantiles à 1/3 et 2/3), ce qui définit trois bins « Court », « Moyen » et « Long » ; pour la figure 5, les exemples sont répartis en 15 bins selon le rang centile de leur longueur (*rank percentile*), puis le macro F1 est calculé dans chaque bin et reporté en fonction de la longueur moyenne du bin. Les modèles sans affinage diminuent entre Court et Moyen puis s'améliorent entre Moyen et Long ; les modèles fine-tunés régressent au fur et à mesure de la longueur.

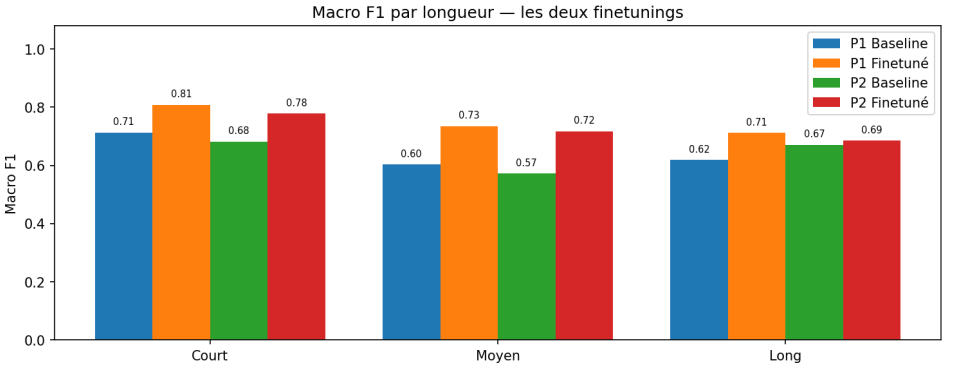

FIGURE 4 – Macro F1 par bin de longueur (terciles : Court / Moyen / Long) pour les modèles sans affinage et modèles fine-tunés.

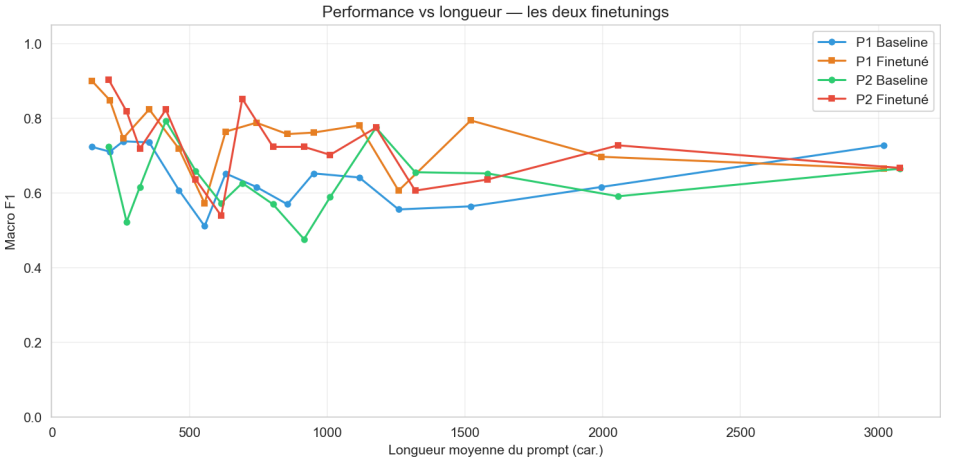

FIGURE 5 – Évolution du macro F1 en fonction de la longueur du prompt (15 bins par rang centile, courbe lissée) pour les deux fine-tunings.

Trois stratégies few-shot. Les trois stratégies few-shot (sélection par type et section, KATE, similarité cosine) atteignent des macro F1 du même ordre : 71,7 % pour la sélection par type et section, 71,2 % pour KATE, 70,9 % pour Cosine. Aucune ne dépasse le fine-tuning Prompt 1 (75,3 % de macro F1), mais elles se situent toujours légèrement en dessous du fine-tuning Prompt 2, sans aucun ré-entraînement. La stratégie par type et section est légèrement en tête des trois. La figure 6 présente la performance des trois stratégies par type de tâche et par section de protocole dans un même graphique : les trois courbes ou barres sont très proches pour chaque sous-groupe, ce qui justifie que les trois stratégies few-shot se comportent de manière très similaire selon le type et la section, avec des variations limitées entre type+section, KATE et Cosine.

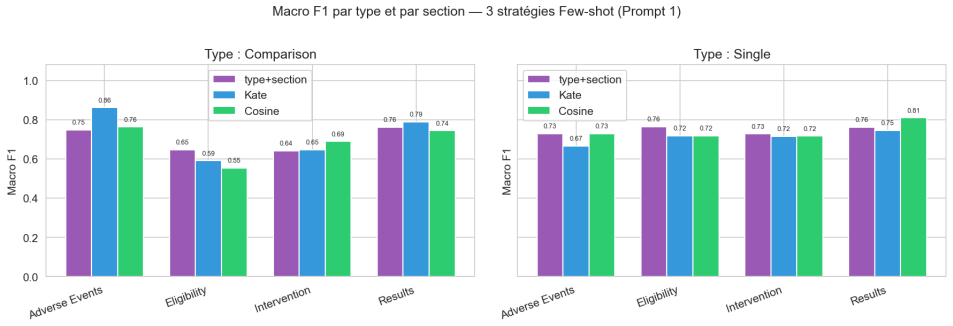

FIGURE 6 – Macro F1 par type de tâche (Single / Comparison) et par section de protocole pour les trois stratégies few-shot (type+section, KATE, cosine). Les trois stratégies montrent des profils très proches, justifiant un comportement similaire.

Synthèse comparative des cinq approches. Le fine-tuning Prompt 1 est le plus performant en macro F1 (75,3 %), suivi du fine-tuning Prompt 2 (72,8 %) et des trois stratégies few-shot (70,9–71,7 %). Pour ce jeu de données, les résultats sont très similaires entre few-shot et fine-tuning : le few-shot se débrouille déjà très bien sans nécessiter de forte puissance de calcul, si bien que dans ce cas le coût d'un fine-tuning ne semble pas justifié. Par ailleurs, les tableaux par type et par section (figures 1 et 6) montrent que la tâche Eligibility semble être la plus difficile ; il peut donc être intéressant de se concentrer sur cette tâche, ce que permet le jeu NLI4PR. Pour la suite de l'analyse (section suivante), on se concentre sur la stratégie KATE : la stratégie few-shot la plus efficace sur NLI4CT est la sélection par type et section, mais celle-ci n'est pas directement réutilisable sur NLI4PR (où il n'y a pas de type ni de section de protocole), alors que KATE l'est. La section suivante (analyse d'erreurs) détaille où les modèles se trompent, où ils sont d'accord, et dans quelle mesure le fine-tuning Prompt 1 et KATE se complètent.

4.2 Résultats NLI4PR

L'évaluation NLI4PR porte sur 3156 exemples de test (1578 en langage patient POL et 1578 en langage médical), avec quatre familles de configurations : les trois prompts (**NLI**, **Clinical Matching**, **CoT**) en **baseline** (sans affinage) et en **finetuné**, ainsi que la stratégie **few-shot KATE** (sans entraînement). Le tableau 2 synthétise l'accuracy (%) en Global, POL et MEDICAL pour toutes ces configurations.

Synthèse des performances. Le **finetuning améliore nettement** les trois prompts par rapport à leurs baselines. Le gain est le plus marqué pour le prompt **NLI** : +13,2 points en global (55,7 % → 68,9 %), avec des améliorations similaires en POL et MEDICAL. Les prompts Clinical Matching et CoT partent de baselines déjà plus élevées (66,2 % et 72,2 %) et gagnent encore respectivement +6,6 et +1,6 points en global après affinage. Au final, le **CoT finetuné** obtient la meilleure accuracy globale (73,8 %) et en MEDICAL (74,2 %) ; le Clinical Matching finetuné reste très proche (72,8 % global, 73,3 % en POL). La stratégie **few-shot KATE** a également été évaluée sur NLI4PR (66,2 % en global, 65,6 % en POL, 66,7 % en MEDICAL). Les résultats restent nettement inférieurs à toutes les configurations par prompt (finetuné) sur ce jeu de données ; nous ne nous sommes donc pas concentrés

TABLE 2 – Précision (accuracy, %) sur NLI4PR — Global (3156 ex.), POL (1578 ex.) et MEDICAL (1578 ex.).

Configuration	Global	POL	MEDICAL
NLI Baseline	55,7	53,8	57,6
NLI Finetuné	**68,9**	68,3	69,6
Clinical Matching Baseline	66,2	65,0	67,4
Clinical Matching Finetuné	72,8	73,3	72,4
CoT Baseline	72,2	70,5	74,0
CoT Finetuné	**73,8**	73,4	**74,2**
Few-shot KATE	66,2	65,6	66,7

sur cette approche pour NLI4PR.

Comparaison par type de langage (POL vs MEDICAL). En baseline, les trois prompts performent légèrement mieux sur le sous-ensemble **MEDICAL** que sur **POL**, avec des écarts de l'ordre de 2 à 4 points. Après finetuning, les écarts entre POL et MEDICAL se réduisent : le CoT finetuné atteint 73,4 % en POL et 74,2 % en MEDICAL. Les figures 7 et 8 illustrent la comparaison des trois prompts en baseline et en finetuné (Global, POL, MEDICAL).

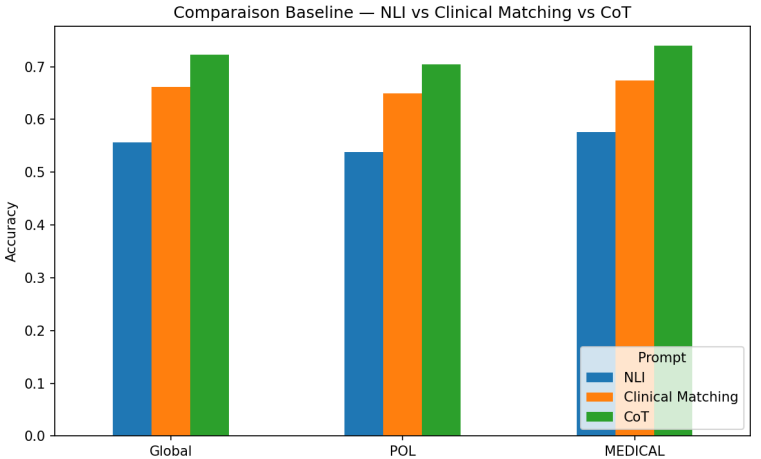

FIGURE 7 – Accuracy des trois prompts (NLI, Clinical Matching, CoT) en **baseline** — Global, POL et MEDICAL.

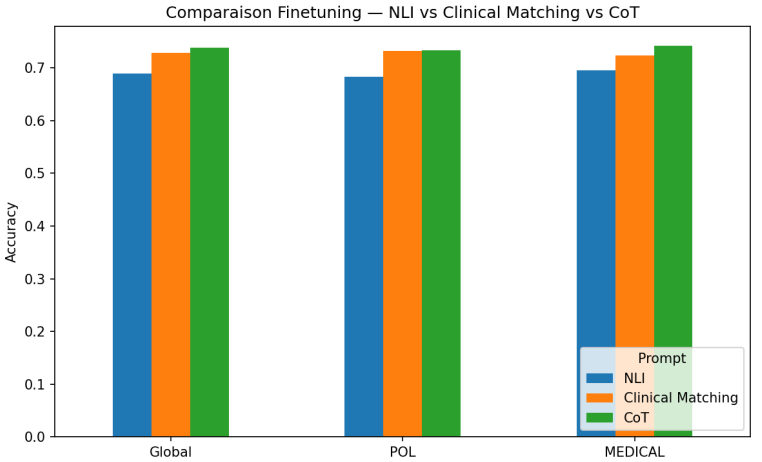

FIGURE 8 – Accuracy des trois prompts (NLI, Clinical Matching, CoT) **finetunés** — Global, POL et MEDICAL. Le CoT finetuné obtient les meilleurs scores.

Modèle sans affinage vs affiné par prompt. Pour chaque prompt, le finetuning apporte plus d'améliorations que de régressions. Par exemple, pour le NLI : 1108 exemples passent de faux (modèle sans affinage) à corrects (finetuné) contre 691 régressions (correct avec le modèle sans affinage, faux après affinage), soit un bilan net de +417 exemples corrects. Les figures 9, 10 et 11 montrent les courbes baseline vs finetuné pour les trois prompts (accuracy Global, POL, MEDICAL). Une matrice de confusion typique (CoT finetuné, combined) est donnée en figure 12 pour illustrer la répartition des prédictions Entailment / Contradiction.

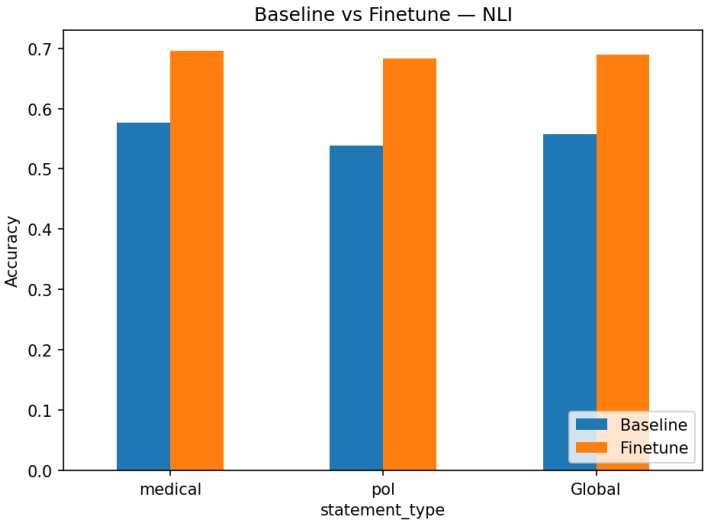

FIGURE 9 – Baseline vs Finetuné — prompt **NLI**. Gain important du finetuning en Global, POL et MEDICAL.

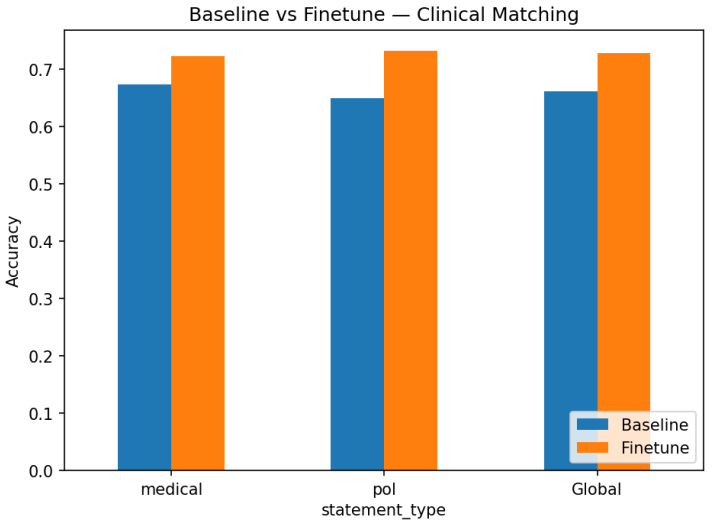

FIGURE 10 – Baseline vs Finetuné — prompt **Clinical Matching**.

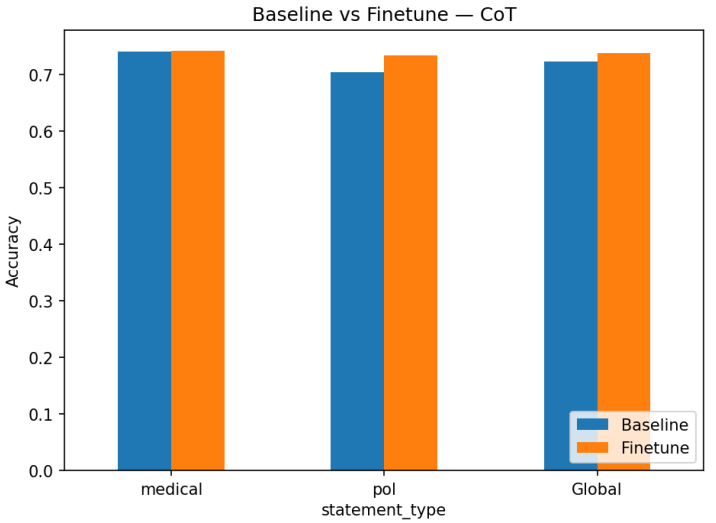

FIGURE 11 – Baseline vs Finetuné — prompt **CoT**. Le modèle sans affinage CoT est déjà élevé ; le finetuning apporte un gain modéré mais consistant.

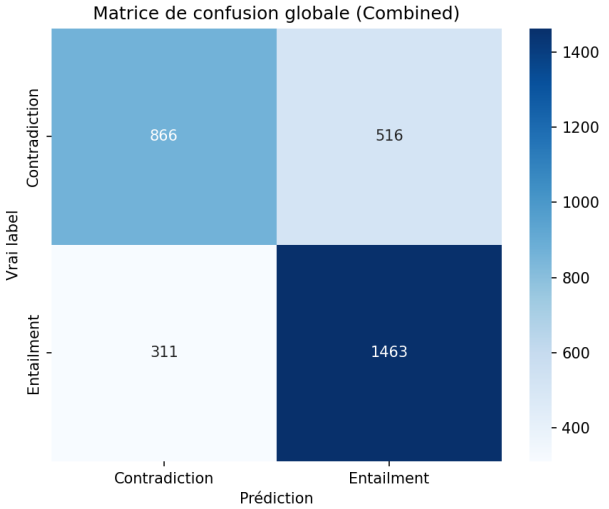

FIGURE 12 – Matrice de confusion — CoT finetuné, ensemble combined (POL + MEDICAL).

Noyau dur d'erreurs. Lorsque *les trois* modèles **baseline** se trompent ensemble (237 exemples en POL, 174 en MEDICAL), ils prédisent à tort **Contradiction** dans la grande majorité des cas : le vrai label est Entailment dans environ **92 %** des cas en POL et **88 %** en MEDICAL. Les baselines ont donc une tendance à sous-déclarer l'éligibilité. À l'inverse, lorsque les trois modèles **finetunés** se trompent ensemble (196 en POL, 174 en MEDICAL), le vrai label est majoritairement **Contradiction** (environ 75 % en POL et 80 % en MEDICAL) : les modèles finetunés tendent alors à prédire à tort Entailment. Nous choisissons **123 candidats** pour l'analyse d'erreurs NLI4PR (section suivante) provenant de l'intersection de ces indices en POL et en MEDICAL pour les modèles **finetunés** (même patient en erreur dans les deux formulations). Nous ciblons les erreurs du finetuning car c'est là que les meilleurs résultats sont obtenus ; l'analyse d'erreurs NLI4PR (section suivante) porte sur ce noyau dur.

5 Analyse d'erreurs

5.1 Analyse d'erreurs NLI4CT

L'analyse d'erreurs porte sur trois axes : la convergence des erreurs entre les deux configurations affinées (Prompt 1 et Prompt 2), entre les trois stratégies few-shot, puis la complémentarité entre le meilleur modèle affiné (Prompt 1) et le meilleur few-shot (KATE). Les effectifs et répartitions ci-dessous proviennent des comparaisons systématiques réalisées sur le Gold test (500 exemples).

Convergence des erreurs entre les deux configurations affinées. On compare les prédictions du Prompt 1 affiné et du Prompt 2 affiné sur les 500 exemples. La répartition des quatre cas d'accord/désaccord est la suivante : 333 exemples où les deux ont raison, 103 où les deux se trompent,

38 où seul le Prompt 1 a raison (P2 en erreur) et 26 où seul le Prompt 2 a raison (P1 en erreur). Les deux modèles sont donc d'accord sur une large majorité des cas (333 + 103 = 436, soit 87,2 %). Les désaccords (64 exemples au total) sont légèrement en faveur du Prompt 1 (38 contre 26), cohérent avec sa meilleure accuracy globale. Les 103 cas où les deux se trompent sont communs aux deux formulations de prompt. La figure 13 synthétise la répartition des cas « les deux modèles affinés se trompent » et « les deux ont raison » par section de protocole.

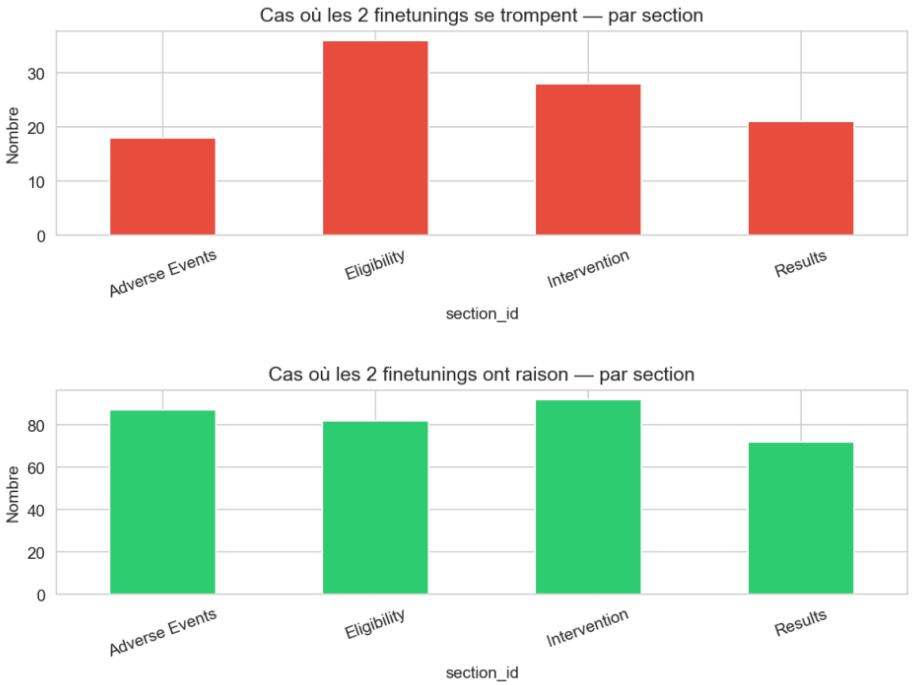

FIGURE 13 – Répartition par section de protocole des cas où les deux modèles affinés (Prompt 1 et Prompt 2) se trompent (en haut) et des cas où les deux ont raison (en bas). Les deux modèles sont nettement plus susceptibles de se tromper sur les sections *Eligibility* et *Intervention* que sur *Results* ou *Adverse Events*.

On observe que, parmi les 103 cas où les deux modèles se trompent, les sections *Eligibility* et *Intervention* concentrent une part plus importante des erreurs communes que les sections *Results* et *Adverse Events*, alors que ces dernières regroupent davantage de cas correctement traités. Même après affinage, les deux modèles restent plus fragiles sur les tâches d'éligibilité et d'intervention que sur les tâches liées aux résultats ou aux événements indésirables, ce qui renforce l'intérêt d'analyses spécifiques sur ces sections et d'une étude complémentaire focalisée sur l'éligibilité (NLI4PR).

Convergence des erreurs entre les trois stratégies few-shot. Nous ne détaillons pas ici l'analyse des désaccords entre les trois stratégies few-shot (sélection par type et section, KATE, similarité cosine). Comme annoncé dans la partie résultats, les trois stratégies se comportent de façon similaire

et font des erreurs proches. On observe les mêmes tendances que pour les deux modèles affinés : les sections Eligibility et Intervention sont surreprésentées dans les erreurs.

Complémentarité modèle affiné Prompt 1 et few-shot KATE. On restreint l'analyse aux prédictions du modèle affiné Prompt 1 (74,2 %) et du few-shot KATE (71,4 %), les deux approches les plus performantes dans chaque famille. Sur le Gold test : 299 exemples où les deux ont raison, 71 où les deux se trompent, 72 où seul l'affinage Prompt 1 a raison et 58 où seul KATE a raison. L'accord domine (299 + 71 = 370, 74 %), mais la complémentarité est nette : 130 exemples (72 + 58) où un seul des deux a raison, chaque approche compensant partiellement l'autre. Pour interpréter ces écarts, une analyse linguistique a été menée sur les quatre sous-ensembles. Les indicateurs utilisés sont : (1) chevauchement lexical entre prémisse et hypothèse (Jaccard : taille de l'intersection sur l'union des mots ; couverture : part des mots de l'hypothèse présents dans la prémisse) ; (2) densité numérique (somme du nombre de chiffres, de pourcentages `nombre%`, d'expressions avec unités *mg*, *years*, etc., et de nombres en toutes lettres dans prémisse et hypothèse) ; (3) négations (nombre d'occurrences de mots de négation, *not*, *no*, *never*, etc., et formes en *n't*, dans prémisse et hypothèse) ; (4) longueur en mots (nombre de tokens alphanumériques). Le détail du calcul de chaque indicateur est donné en annexe (tableau 8). Le tableau 3 résume les moyennes pour chacun des quatre cas.

TABLE 3 – Moyennes des indicateurs linguistiques par cas (modèle affiné Prompt 1 vs few-shot KATE).

Cas	Jaccard lex.	Couverture	Densité num.	Négations	Mots prémisse	Mots hypothèse
Les 2 corrects	0,1045	0,3354	41,79	0,68	113,43	21,50
Les 2 en erreur	0,1050	0,3799	40,66	1,99	169,06	21,51
P1$^{\checkmark}$ KATE$^{\times}$	0,1073	0,3553	43,72	0,88	124,26	22,54
P1$^{\times}$ KATE$^{\checkmark}$	0,1004	0,3958	62,74	1,41	220,84	24,47

Les tests de Kruskal-Wallis indiquent que les quatre groupes se distinguent significativement par la densité numérique (`numeric_total`) et la longueur de la prémisse (`words_premise`). Les cas où les deux se trompent (71) contiennent en moyenne plus de négations que les cas où les deux ont raison (test de Mann-Whitney, $p < 0{,}05$) : les deux approches échouent plus souvent sur des contradictions à base de négations explicites. À l'inverse, dans le sous-ensemble P1 en erreur et KATE correct (58 exemples), les exemples ont une densité numérique plus élevée et des prémisses plus longues ($p < 0{,}05$) : le few-shot KATE, avec des exemples sémantiquement proches, semble mieux exploiter le contexte numérique et les critères longs. Dans le sous-ensemble P1 correct et KATE en erreur (72 exemples), le profil (moins numérique, prémisses plus courtes en moyenne) correspond au domaine où le modèle affiné tire mieux parti de l'affinage. En pratique, ces résultats suggèrent qu'un système hybride ou un choix ciblé (par ex. préférer KATE sur les cas très numériques ou à longue prémisse, le modèle affiné Prompt 1 ailleurs) pourrait tirer parti de cette complémentarité et potentiellement dépasser la précision de chaque approche seule.

Analyses univariées par approche (section Eligibility). Pour voir si l'on peut tirer des conclusions en regardant chaque approche indépendamment, on restreint l'analyse à la section Eligibility (la tâche la plus difficile sur NLI4CT) et on compare les indicateurs linguistiques selon que KATE a raison ou se trompe, puis selon que le modèle affiné P1 a raison ou se trompe. Les deux tableaux ci-dessous (KATE : tableau 4, P1 : tableau 5) résument les moyennes pour chaque sous-ensemble. En regardant

le tableau KATE seul : quand KATE se trompe (47 exemples), les exemples ont en moyenne plus de négations (3,23 vs 1,79), une prémisse plus longue (195 vs 159 mots) et une densité numérique légèrement plus élevée ; quand KATE a raison, le profil est plus léger (moins de négations, prémisses plus courtes). En regardant le tableau P1 seul : quand le modèle affiné P1 se trompe (41 exemples), les exemples ont une longueur de prémisse très élevée (320 mots en moyenne vs 105 quand P1 a raison), une densité numérique plus forte (25,9 vs 11,8) et beaucoup plus de négations (4,44 vs 1,34) ; quand P1 a raison, les exemples sont plus courts et moins chargés. Les deux tableaux, pris indépendamment, pointent donc vers des profils d'échec distincts : KATE échoue davantage sur des cas avec plus de négations et des prémisses longues ; le modèle affiné P1 échoue surtout sur des cas très longs, très numériques et à forte présence de négations. Ces conclusions sur la section Eligibility (NLI4CT) motivent la section suivante : on regarde si le jeu NLI4PR, centré sur l'éligibilité, exhibe les mêmes phénomènes (prémisses courtes, densité numérique, négations) sur les exemples où les modèles se trompent.

TABLE 4 – Moyennes des indicateurs linguistiques — Few-shot KATE a raison vs KATE se trompe (section Eligibility, 132 ex.).

	Jaccard lex.	Couverture	Densité num.	Négations	Mots prémisse	Mots hypothèse
KATE se trompe (47)	0,10	0,40	17,8	3,23	195,6	23,9
KATE a raison (85)	0,12	0,39	15,3	1,79	159,0	23,8

TABLE 5 – Moyennes des indicateurs linguistiques — Modèle affiné P1 a raison vs P1 se trompe (section Eligibility, 132 ex.).

	Jaccard lex.	Couverture	Densité num.	Négations	Mots prémisse	Mots hypothèse
P1 se trompe (41)	0,10	0,48	25,9	4,44	320,4	25,3
P1 a raison (91)	0,11	0,35	11,8	1,34	105,2	23,2

Synthèse. L'analyse d'erreurs sur NLI4CT confirme que les cinq approches (deux modèles affinés, trois stratégies few-shot) ont davantage de difficultés sur la section Eligibility (et, pour les modèles affinés, sur Intervention), ce qui renforce la légitimité d'étudier un jeu centré sur l'éligibilité comme NLI4PR. La complémentarité entre le modèle affiné Prompt 1 et le few-shot KATE suggère qu'un système hybride pourrait être plus performant : les deux approches se complètent selon le profil du prompt (longueur, densité numérique, négations). Enfin, l'analyse univariée par approche (section Eligibility) motive l'étude d'erreurs sur NLI4PR : il s'agit de vérifier si l'on y observe les mêmes phénomènes linguistiques associés aux succès et aux échecs de chaque méthode.

5.2 Analyse d'erreurs NLI4PR

Une **analyse linguistique** a été menée sur notre selection de 123 candidats, en les comparant au reste des indices du jeu de test (comme pour NLI4CT). Les métriques utilisées sont : chevauchement lexical (Jaccard), couverture lexicale, densité numérique (chiffres, pourcentages, unités), nombre de négations, longueur de la prémisse et du statement, et présence de mots-clés d'essai. Les tableaux 6 et 7 résument les moyennes candidats vs autres (POL et MEDICAL). Les candidats se distinguent par des **prémisses plus courtes** (environ 198 mots vs 252 pour les autres), une **densité numérique plus faible** (environ 31–33 vs 37–40), et une **couverture lexicale légèrement plus basse**. En MEDICAL,

les candidats ont en moyenne **plus de négations dans le statement** (1,72 vs 1,42). Ces profils suggèrent que le noyau dur d'erreurs correspond à des cas où les critères sont moins longs et moins chargés en données numériques, avec des formulations potentiellement plus ambiguës (négations). Les figures 14 et 15 illustrent la comparaison détaillée des métriques entre candidats et autres indices.

TABLE 6 – Moyennes des indicateurs linguistiques — candidats vs autres (POL).

Indicateur	Candidats	Autres	Δ
Longueur prémisse (mots)	198	252	−53
Densité numérique totale	30,9	37,3	−6,4
Couverture lexicale	0,183	0,196	−0,012
Négations (statement)	1,02	0,91	+0,10

TABLE 7 – Moyennes des indicateurs linguistiques — candidats vs autres (MEDICAL).

Indicateur	Candidats	Autres	Δ
Longueur prémisse (mots)	198	252	−54
Densité numérique totale	32,8	40,1	−7,3
Couverture lexicale	0,213	0,233	−0,020
Négations (statement)	1,72	1,42	+0,30

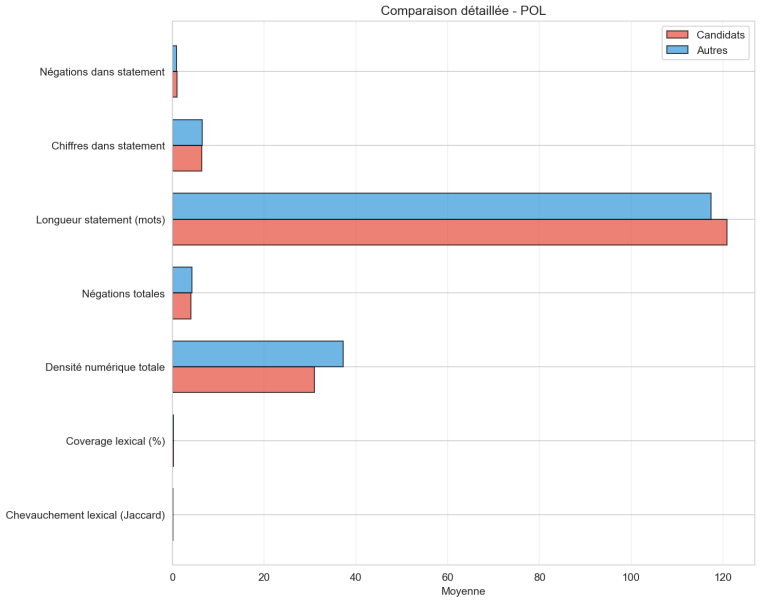

FIGURE 14 – Comparaison des métriques linguistiques — candidats vs autres indices (POL).

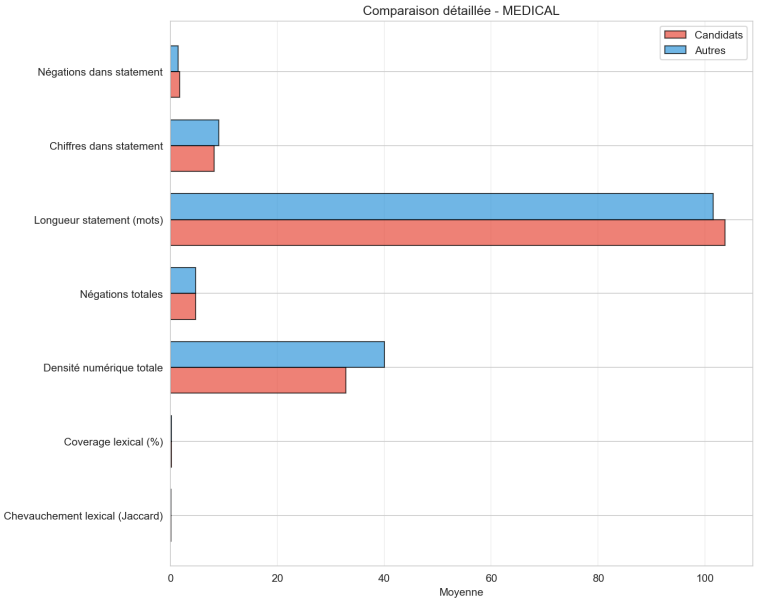

FIGURE 15 – Comparaison des métriques linguistiques — candidats vs autres indices (MEDICAL).

En résumé, le finetuning réduit le nombre de cas « tous faux » (237 → 196 en POL) et rééquilibre les prédictions ; le résidu d'erreurs communes (123 candidats) correspond à un profil linguistique distinct (prémisses plus courtes, moins de densité numérique, davantage de négations en MEDICAL), ce qui peut orienter des améliorations ciblées (ex. données d'entraînement complémentaires ou prompts adaptés à ces cas).

6 Conclusion et perspectives

7 Limitations

A Définition des indicateurs linguistiques (section 5.1)

Le tableau 8 précise le calcul de chaque indicateur utilisé dans l'analyse linguistique (complémentarité P1 / KATE et analyses univariées).

TABLE 8 – Moyen de calcul des indicateurs linguistiques.

Indicateur	Nom interne	Calcul
Jaccard lexical	`lexical_jaccard`	Mots = tokens alphanumériques (minuscules). Jaccard = $\|P \cap H\|/\|P \cup H\|$ sur les ensembles de mots de la prémisse P et de l'hypothèse H.
Couverture	`lexical_coverage`	$\|P \cap H\|/\|H\|$ si $H \neq \emptyset$: part des mots de l'hypothèse présents dans la prémisse.
Densité numérique	`numeric_total`	Somme (prémisse + hypothèse) de : nombre de chiffres (`\d`), d'occurrences `nombre%`, d'expressions `nombre + unité` (mg, g, ml, years, months, etc.), et de nombres en toutes lettres (one, two, …, hundred, thousand, etc.).
Négations	`neg_total`	Somme prémisse + hypothèse du nombre d'occurrences de mots de négation (*not*, *no*, *never*, *none*, *cannot*, etc.) et de formes en *n't* (tokenisé).
Mots prémisse	`words_premise`	Nombre de tokens alphanumériques dans la prémisse.
Mots hypothèse	`words_hypothesis`	Nombre de tokens alphanumériques dans l'hypothèse.

A.1 Rappels importants

— Le style bibliographique tient compte des champs `doi` et `hal_id`. Des exemples sont donnés dans la bibliographie (Pereira & Warren, 1983; Bernhard, 2007; Tellier, 2008). Voir également le fichier `biblio.bib` fourni.

— Le *package* `hyperref` est chargé automatiquement par le fichier de style `jeptaln2020.sty`. Certains *packages* particuliers doivent être donc chargés avant, certains après, suivant les compatibilités avec `hyperref` (voir les compatibilités dans la documentation).

— Si vous utilisez les symboles utf-8 pour les guillements français, ne pas oublier les espaces insécables ~ après les guillemets ouvrants ou avant les guillements fermants : « test » (`«~test~»`). Sinon, vous pouvez utiliser les commandes `\og` et `\fg` : « test » (`\og test \fg{}`).

— Exemple d'utilisation des nombres décimaux, afin d'éviter le placement d'un espace insécable : `$1,2$ $1.2$` ou `$\num{1,2}$ $1{,}2$`, ou encore `$\num{1.2}$ \num{1,2}`.

— Lorsque vous citez un article disponible sur arXiv, pensez à vérifier si cet article est une pré-publication (`@misc`) ou a déjà été publié (`@inproceedings` ou `@article` ou autre). Dans tous les cas, il est possible de mettre un lien dans l'entrée bibliographique, par exemple en utilisant le champ note : `note = "arXiv~: \href{https://arxiv.org/abs/NNN.MMM}{NNN.MMM}"`

— Il peut aussi y avoir (très très rarement) des problèmes à la compilation lorsqu'une url s'étend sur deux pages. Une solution, dans ce cas, est de compiler avec l'option `draft` ajoutée à la commande `\documentclass[10pt,twoside]{article}` pour que la position soit correctement calculée, puis sans l'option pour que le lien devienne cliquable.

Références

BENAMARA F., HATOUT N., MULLER P. & OZDOWSKA S., Éds. (2007). *Actes de TALN 2007 (Traitement automatique des langues naturelles)*, Toulouse. ATALA, IRIT.

BERNHARD D. (2007). Apprentissage non supervisé de familles morphologiques par classification ascendante hiérarchique. In (Benamara *et al.*, 2007), p. 367–376. HAL : hal-00800342.

CHOMSKY N. & SCHÜTZENBERGER M.-P. (1963). The algebraic theory of context-free languages. *Studies in Logic and the Foundations of Mathematics*, **35**, 118–161. DOI : 10.1016/S0049-237X(08)72023-8.

DIAS G., Éd. (2015). *Actes de TALN 2015 (Traitement automatique des langues naturelles)*, Caen. ATALA, HULTECH.

HINZEN W., MACHERY E. & WERNING M., Éds. (2012). *The Oxford Handbook of Compositionality*. Oxford. DOI : 10.1093/oxfordhb/9780199541072.001.0001.

JOSHI A. K. (1985). Tree-adjoining grammars : How much context sensitivity is required to provide reasonable structural descriptions ? In D. R. DOWTY, L. KARTTUNEN & A. M. ZWICKY, Éds., *Natural Language Parsing : Psychological, Computational, and Theoretical Perspectives*, Studies in Natural Language Processing, chapitre 6, p. 206–250. Cambridge University Press. DOI : 10.1017/CBO9780511597855.007.

LAIGNELET M. & RIOULT F. (2009). Repérer automatiquement les segments obsolescents à l'aide d'indices sémantiques et discursifs. In A. NAZARENKO & T. POIBEAU, Éds., *Actes de TALN 2009 (Traitement automatique des langues naturelles)*, Senlis : ATALA LIPN.

LANGLAIS P. & PATRY A. (2007). Enrichissement d'un lexique bilingue par analogie. In (Benamara *et al.*, 2007), p. 101–110.

PEREIRA F. C. N. & WARREN D. H. D. (1983). Parsing as deduction. In *21st Annual Meeting of the Association for Computational Linguistics*, p. 137–144, Cambridge, Massachusetts, USA : Association for Computational Linguistics. DOI : 10.3115/981311.981338.

POLLARD C. (1984). *Generalized Phrase Structure Grammars, Head Grammars, and Natural Language*. Thèse de doctorat, Stanford University, CA.

SERETAN V. & WEHRLI E. (2007). Collocation translation based on sentence alignment and parsing. In (Benamara *et al.*, 2007), p. 401–410.

TELLIER I. (2008). How to Split Recursive Automata. In A. CLARK, F. COSTE & L. MICLET, Éds., *Grammatical Inference : Algorithms and Applications. 9th International Colloquium, ICGI 2008 Saint-Malo, France, September 22-24, 2008 Proceedings*, volume 5278 de *LNAI*, p. 200–212 : Springer. DOI : 10.1007/978-3-540-88009-7_16, HAL : inria-00341770.

A.2 Titre de la première sous-partie

— Une liste à puce

1. Une liste numérotée

Un tableau	
	Les cellules ainsi que le tableau sont centrés

TABLE 9 – Un tableau

FIGURE 16 – Une image comme figure

Un texte qui termine par une note de bas de page [1].

Le renvoi à une référence bibliographique : (Bernhard, 2007), et le renvoi à plusieurs références : (Dias, 2015; Langlais & Patry, 2007). Référence à un article de conférence (Tellier, 2008), à un article de revue (Chomsky & Schützenberger, 1963), à un livre (Hinzen *et al.*, 2012), à une thèse (Pollard, 1984), à un chapitre dans un ouvrage collectif (Joshi, 1985).

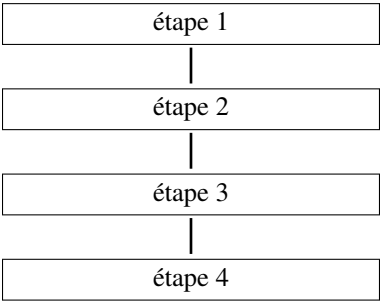

FIGURE 17 – Un schéma comme figure

1. Que voici !