Rapport d'analyse des résultats
NLI4CT : Finetuning vs Few-shot

Analyse automatique des notebooks

3 mars 2026

Table des matières

1 Introduction **2**

2 Accuracy globale **2**
2.1 Comparaison des approches 2

3 Résultats par type (Single vs Comparison) **2**

4 Résultats par section **3**
4.1 Prompt 1 (finetuné) 3
4.2 Prompt 2 (finetuné) 3
4.3 Few-shot (Prompt 1) 3

5 Longueur du prompt et performance **4**

6 Régressions et améliorations (Baseline vs Finetuné) **5**

7 Parties 8, 9 et 10 du notebook compare_error (cœur de l'analyse) **5**
7.1 Section 8 : Accord / désaccord entre les 3 approches 5
7.2 Section 8b : Comparaisons deux-à-deux 6
7.2.1 P1 Finetuné vs P2 Finetuné 6
7.2.2 P1 Finetuné / P2 Finetuné vs Few-shot 6
7.3 Section 9 : Cas où les 3 approches se trompent (ou au moins 2) 7
7.4 Section 10 : Cas où les 3 approches ont raison 7
7.5 Section 10b : Exemples pour analyse et répartition par type/section 7

8 Matrices de confusion et erreurs **10**

9 Synthèse par approche **11**
9.1 Prompt 1 (error_analysis_prompt1) 11
9.2 Prompt 2 (error_analysis_prompt2) 11
9.3 Few-shot Prompt 1 (error_analysis_fewshot_prompt1) 11

10 Conclusions **11**

1 Introduction

Ce rapport synthétise les résultats des analyses d'erreurs réalisées sur le jeu NLI4CT (Natural Language Inference for Clinical Trials), à partir des notebooks suivants :

- `error_analysis_prompt1.ipynb` : analyse Prompt 1 (baseline vs finetuné)
- `error_analysis_prompt2.ipynb` : analyse Prompt 2 (baseline vs finetuné)
- `error_analysis_fewshot_prompt1.ipynb` : analyse Few-shot Prompt 1
- `compare_error.ipynb` : comparaison des trois approches (P1 Finetuné, P2 Finetuné, Few-shot)

Jeu de test : 500 exemples (gold test). Les métriques sont l'accuracy globale et les répartitions par type (Single / Comparison), par section (Eligibility, Intervention, Results, Adverse Events), et par longueur de prompt.

2 Accuracy globale

2.1 Comparaison des approches

Table 1 – Accuracy globale (%).

Approche	Accuracy
P1 Baseline	65,80%
P1 Finetuné	74,20%
P1 Few-shot	72,00%
P2 Baseline	65,20%
P2 Finetuné	71,80%

Le finetuning améliore la baseline pour les deux prompts (P1 : +8,4 points, P2 : +6,6 points). Le few-shot (Prompt 1) est entre baseline et finetuné P1 (72%).

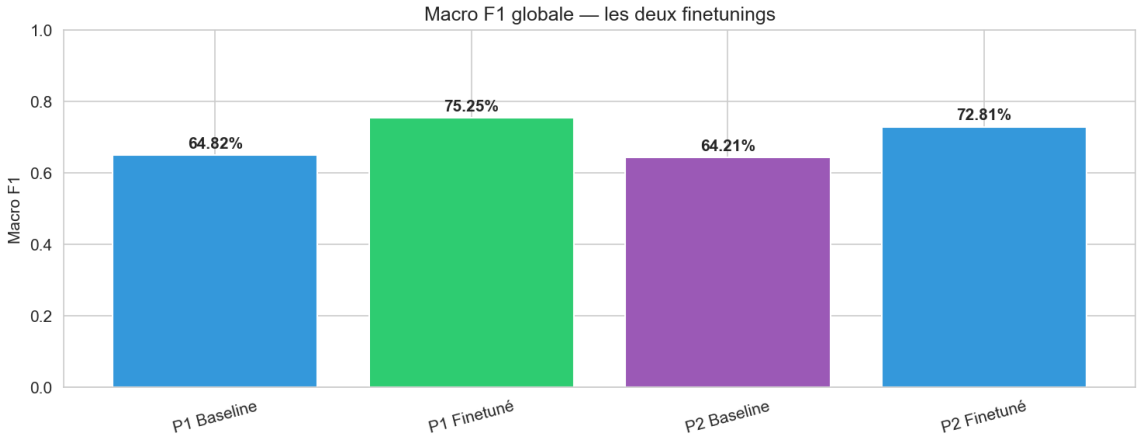

Figure 1 – Accuracy globale — tous les prompts et Few-shot.

3 Résultats par type (Single vs Comparison)

D'après `compare_error.ipynb`, les accuracy par type sont cohérentes avec la synthèse : Comparison est plus difficile que Single pour tous les modèles.

Table 2 – Accuracy par type (Comparison / Single) — valeurs typiques du compare.

Type	P1 Bl	P1 FT	P2 Bl	P2 FT	P1 FS
Comparison	62,4%	72,0%	60,1%	67,9%	69,7%
Single	70,8%	76,9%	72,0%	76,4%	74,7%

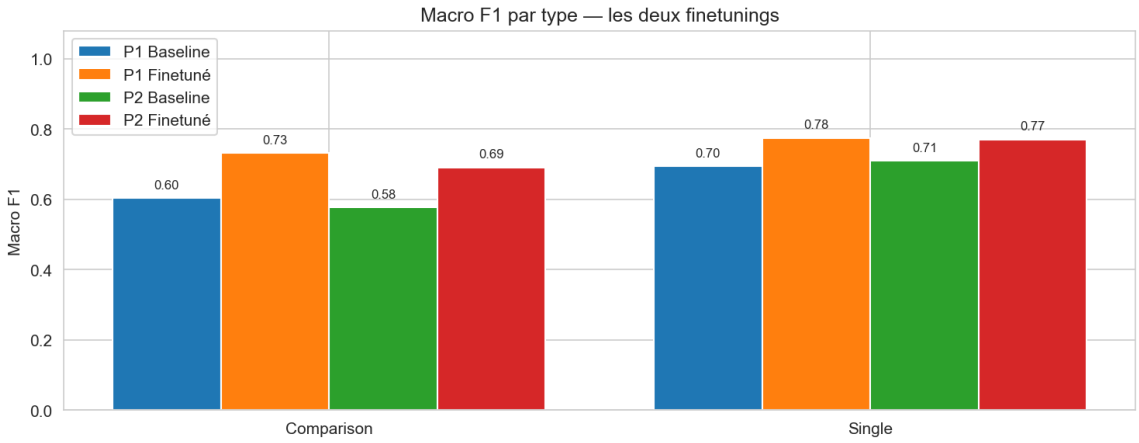

Figure 2 – Accuracy par type (Single / Comparison).

4 Résultats par section

Les sections les plus difficiles (nombre d'erreurs) et les meilleures accuracy (finetuné / few-shot) sont résumées ci-dessous.

4.1 Prompt 1 (finetuné)

— Sections les plus difficiles (nombre d'erreurs) : Eligibility (41), Intervention (36), Results (27).
— Meilleures accuracy par section (finetuné) : Adverse Events 79,2%, Intervention 74,6%, Results 74,5%.
— Types : Comparison 72,0%, Single 76,9%.

4.2 Prompt 2 (finetuné)

— Sections les plus difficiles : Eligibility (45), Intervention (42), Results (28).
— Meilleures accuracy par section : Adverse Events 78,3%, Results 73,6%, Intervention 70,4%.
— Types : Comparison 67,9%, Single 76,4%.

4.3 Few-shot (Prompt 1)

— Sections les plus difficiles : Intervention (44), Eligibility (40), Adverse Events (31).
— Meilleures accuracy par section : Results 76,4%, Adverse Events 74,2%, Eligibility 69,7%.
— Types : Comparison 69,7%, Single 74,7%.

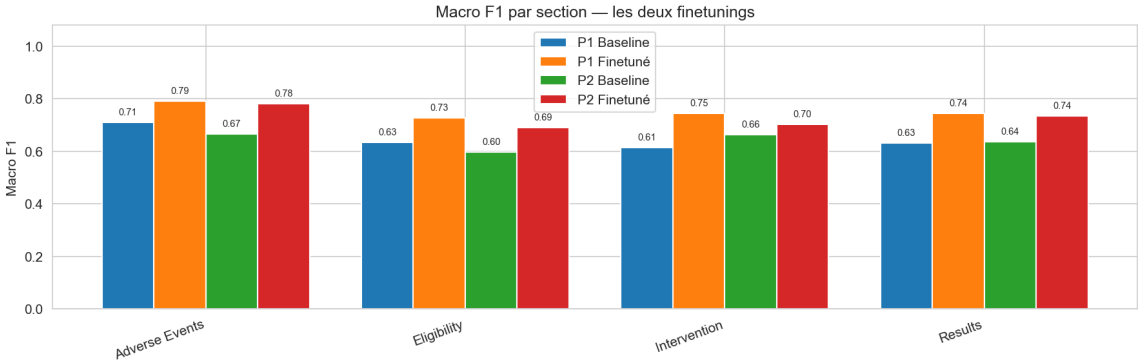

FIGURE 3 – Accuracy par section (toutes approches).

5 Longueur du prompt et performance

Pour les modèles finetunés, les erreurs correspondent en moyenne à des prompts plus longs que les corrects.

TABLE 3 – Longueur moyenne du prompt (caractères).

	Longueur (corrects)	Longueur (erreurs)
Prompt 1 (finetuné)	871	1406
Prompt 2 (finetuné)	932	1420
Few-shot P1	1017	988

Pour le few-shot, la différence de longueur entre corrects et erreurs est faible (1017 vs 988). Pour le finetuning, les erreurs sont nettement associées à des prompts plus longs.

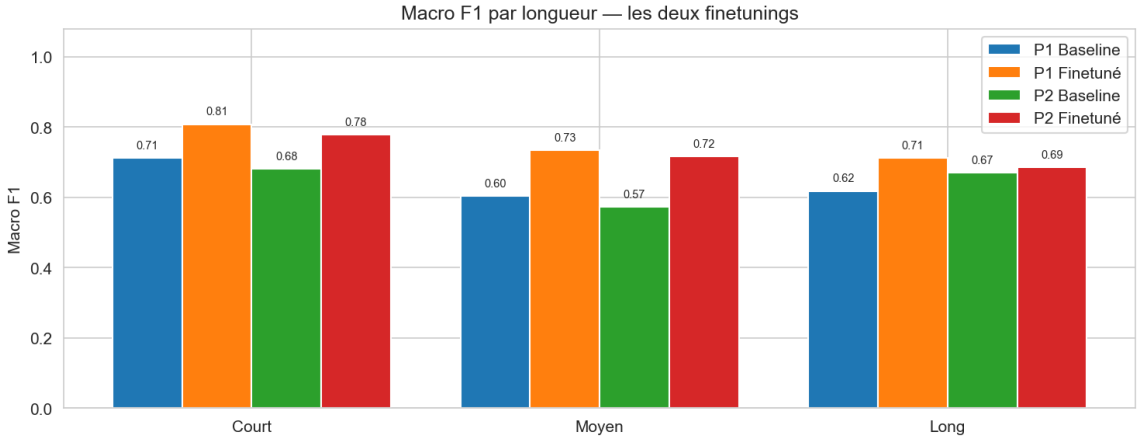

FIGURE 4 – Accuracy par bin de longueur (Court / Moyen / Long).

6 Régressions et améliorations (Baseline vs Finetuné)

Table 4 – Régressions et améliorations par rapport à la baseline.

	Nombre
P1 Régressions (Bl correct, FT faux)	60
P1 Améliorations (Bl faux, FT correct)	102
P2 Régressions	60
P2 Améliorations	93
P1 Few-shot régressions vs P1 FT	61
P1 Few-shot améliorations vs P1 FT	72

Le finetuning apporte plus d'améliorations que de régressions pour les deux prompts. Le few-shot (P1) a légèrement plus de régressions que d'améliorations par rapport au P1 Finetuné (61 vs 72).

7 Parties 8, 9 et 10 du notebook compare_error (cœur de l'analyse)

Les sections 8, 8b, 9, 10 et 10b du notebook `compare_error.ipynb` constituent le cœur de la comparaison entre les trois approches (P1 Finetuné, P2 Finetuné, Few-shot) : quand les modèles se trompent ensemble ou quand l'un compense l'autre.

7.1 Section 8 : Accord / désaccord entre les 3 approches

Sur les 500 exemples où les trois approches sont évaluées (Few-shot P1 chargé), on forme pour chaque exemple un pattern (P1_ft, P2_ft, FS) avec 1 = correct, 0 = erreur. On compte :

Table 5 – Patterns d'accord P1 Finetuné / P2 Finetuné / Few-shot (1 = correct, 0 = erreur).

Pattern	Description	Effectif
111	Les 3 corrects	279
000	Les 3 en erreur	59
110	P1 ok, P2 ok, FS erreur	54
101	P1 ok, P2 erreur, FS ok	20
011	P1 erreur, P2 ok, FS ok	17
100	P1 ok, P2 erreur, FS erreur	18
010	P1 erreur, P2 ok, FS erreur	9
001	P1 erreur, P2 erreur, FS ok	44

Interprétation : 111 = consensus succès (279, 55,8%). 000 = échec commun (59, 11,8%) — cas les plus difficiles. 001 (44) = seul le Few-shot a raison (few-shot compense). 110 (54) = les deux FT ont raison, FS se trompe (finetuning plus fiable). Les autres patterns décrivent les désaccords entre un seul finetuné et le reste.

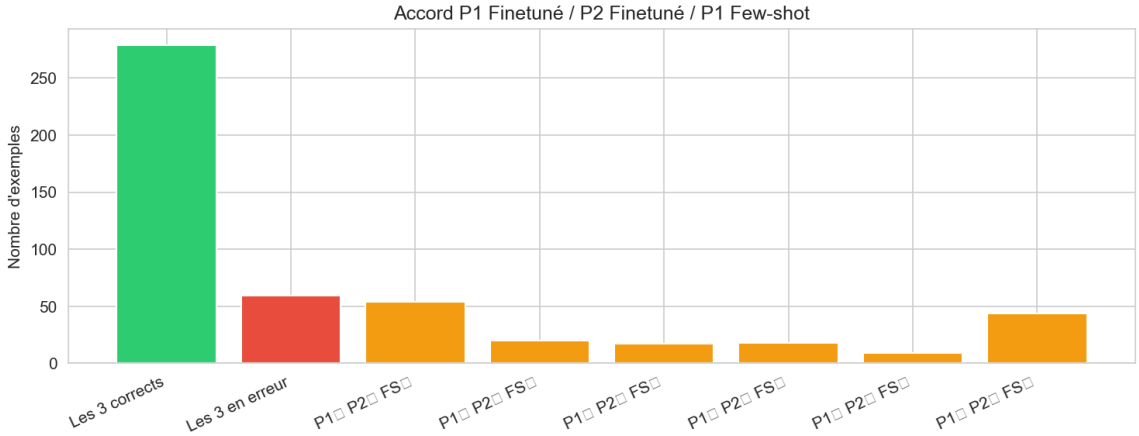

FIGURE 5 – Section 8 : répartition des patterns d'accord entre P1 FT, P2 FT et Few-shot.

7.2 Section 8b : Comparaisons deux-à-deux

Pour chaque paire de modèles on compte : les deux corrects, A correct B faux, A faux B correct, les deux en erreur.

7.2.1 P1 Finetuné vs P2 Finetuné

TABLE 6 – Accord P1 Finetuné vs P2 Finetuné.

Cas	Effectif
Les deux corrects	333
P1 correct, P2 faux	38
P1 faux, P2 correct	26
Les deux en erreur	103

Les deux modèles finetunés sont d'accord sur 333 + 103 = 436 exemples (87,2%). P1 FT est seul correct 38 fois, P2 FT 26 fois.

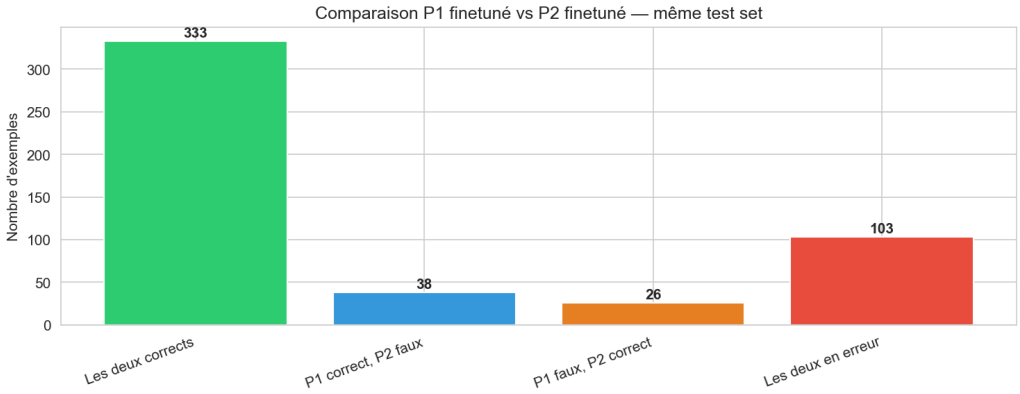

FIGURE 6 – Comparaison deux-à-deux : P1 Finetuné vs P2 Finetuné.

7.2.2 P1 Finetuné / P2 Finetuné vs Few-shot

Les tableaux (P1 vs FS, P2 vs FS) sont affichés dans la section 8b et regroupés dans la figure 7. On en déduit où le few-shot « sauve » un exemple (correct alors que le FT se trompe) ou où

le finetuné est préférable.

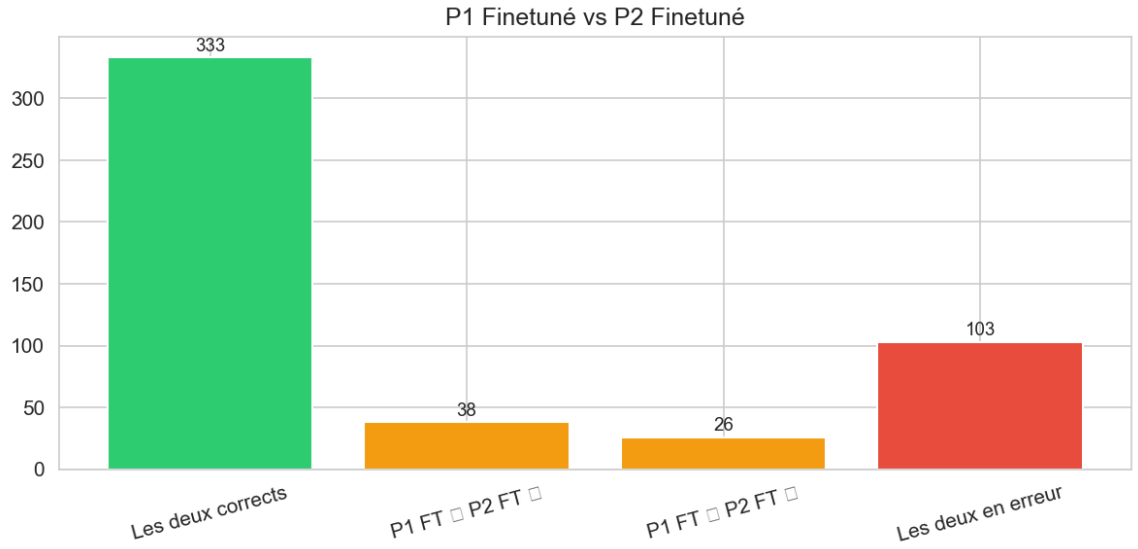

FIGURE 7 – Accord deux-à-deux : P1 vs P2, P1 vs Few-shot, P2 vs Few-shot.

7.3 Section 9 : Cas où les 3 approches se trompent (ou au moins 2)

On définit : **Les 3 en erreur** = pattern 000 (59 exemples). **Au moins 2 en erreur** = au moins deux des trois se trompent (130 exemples). Le notebook construit `detail_3wrong` (index, type, section_id, true_label, pred_P1, pred_P2, pred_FS) et l'exporte en `three_approaches_wrong.csv`. La répartition par section des 59 cas (figure 8) montre si les échecs communs sont concentrés (p.ex. Eligibility, Intervention). Ces 59 cas sont les plus difficiles ; bons candidats pour rééquilibrage ou revue manuelle.

TABLE 7 – Section 9 : effectifs erreur commune.

	Effectif
Les 3 en erreur	59
Au moins 2 en erreur	130

7.4 Section 10 : Cas où les 3 approches ont raison

Les 3 corrects = pattern 111 (279). **Au moins 2 corrects** = 370. La répartition par section des 279 est en figure 9.

TABLE 8 – Section 10 : effectifs succès commun.

	Effectif
Les 3 corrects	279
Au moins 2 corrects	370

7.5 Section 10b : Exemples pour analyse et répartition par type/section

Cinq exemples aléatoires (seed 42) pour chacun des trois cas : (1) Les 3 se trompent (000, 59 ex.) ; (2) P1 et P2 FT se trompent, Few-shot a raison (001, 44 ex.) ; (3) Few-shot se trompe, P1 et P2 FT ont raison (110, 54 ex.). Pour *chaque* cas, le notebook affiche la **répartition par type** et par **section_id**. Les 5 exemples affichés pour chaque cas sont les suivants.

Cas 1 — Les 3 se trompent (000)

Index 7 (Comparison, Eligibility). Vrai : Contradiction. P1/P2/FS : Entailment. Premise : History of allergic reactions attributed to compounds of similar chemical or biologic composition to mesna or other agents (e.g. sulfur containing drugs...). Hypothesis : Any patients with Documented allergy to cephalosporin or trimethoprim/sulfamethoxazole will not be eligible...

Index 97 (Comparison, Eligibility). Vrai : Contradiction. P1/P2/FS : Entailment. Premise : Inclusion Criteria : 18 years or older, Histologically or cytologically confirmed metastatic and/or adva...Hypothesis : Unlike the primary trial, patients must be diagnosed with a mutation in PTEN, BRAF, KRAS, NRAS, PI3KCA, ErbB1, ErbB2...

Index 310 (Single, Results). Vrai : Entailment. P1/P2/FS : Contradiction. Premise : Outcome Measurement : Percentage of Participants With Disease Progression or Death ; PFS was defined as the time from firs...Hypothesis : the Bevacizumab cohort of the primary trial had a higher incidence of Disease Progression or Death than the Bevacizumab + Capecitabine cohort.

Index 150 (Comparison, Eligibility). Vrai : Entailment. P1/P2/FS : Contradiction. Premise : NUT midline carcinoma (ectopic expression of NUT protein, IHC and/or BRD-NUT gene translocation...). Hypothesis : Patients with NUT midline carcinoma or Castrate-resistant prostate cancer, or inflammatory breast ca...

Index 384 (Comparison, Eligibility). Vrai : Entailment. P1/P2/FS : Contradiction. Premise : Diagnosis of anemia only due to iron-deficiency ; Diagnosis of thalasemic syndromes ; Diagnosis of fibromyalgia. Hypothesis : Any cancer patient diagnosed with either fibromyalgia, thalasemic syndromes or anemia cannot be eligible for both the primary trial and the secondary...

Cas 2 — P1 et P2 FT se trompent, Few-shot a raison (001)

Index 284 (Comparison, Results). Vrai : Contradiction. P1/P2 : Entailment, FS : Contradiction. Premise : Outcome Measurement : Safety ; toxicity graded following NCI Common Toxicity Criteria 2.0. Time frame : 2 ye...Hypothesis : There were more participants in the primary trial than in the secondary trial.

Index 421 (Comparison, Eligibility). Vrai : Entailment. P1/P2 : Contradiction, FS : Entailment. Premise : Inclusion Criteria : Adults with histologically or cytologically confirmed breast adenocarcinoma, bone mets, ECOG 0, 1 o...Hypothesis : Patients with histologically confirmed stage 4 breast adenocarcinoma that is either ER positive, PR positive or HER2/neu negative are eligible for bot...

Index 21 (Single, Adverse Events). Vrai : Contradiction. P1/P2 : Entailment, FS : Contradiction. Premise : Hypertension 1/8 (12.50%), Hepatotoxicity 3/8 (37.50%), Pancreatectomy 1/8 (12.50%). Hypothesis : in the primary trial there were 10 times the number of Hepatotoxicity cases as there were cases of hypertension and Pancreatectomy.

Index 173 (Comparison, Intervention). Vrai : Contradiction. P1/P2 : Entailment, FS : Contradiction. Premise : INTERVENTION 1 : Denosumab 120 mg subcutaneously every 4 weeks...INTERVENTION 1 : Intraope...Hypothesis : the primary trial requires patients to receive 120 milligrams of denosumab injected subcutaneously every month, the secondary trial does not require i...

Index 260 (Comparison, Results). Vrai : Entailment. P1/P2 : Contradiction, FS : Entailment. Premise : Outcome Measurement : Time to Progression (TTP)...Hypothesis : the primary trial reports the Time to Progression in months for a total of 156 patients across the two cohorts, on the other hand, the secondary trial...

Cas 3 — Few-shot se trompe, P1 et P2 FT ont raison (110)

Index 65 (Comparison, Adverse Events). Vrai : Contradiction. P1/P2 : Contradiction, FS : Entailment. Premise : Adverse Events 1 : Total : 0/104 (0.00%) ; Adverse Events 1 : Total : 45/128 (35.16%), Anaemia 3/128 (2.34%)...Hypothesis : The most common adverse event in the

secondary trial was Anaemia, affecting more than 5% of patients, there were no recorded AEs in the primary trial.

Index 5 (Comparison, Adverse Events). Vrai : Entailment. P1/P2 : Entailment, FS : Contradiction. Premise : Adverse Events 1 : Total : 0/10 (0.00%) ; 0/1699 (0.00%) ; 0/2004 (0.00%). Hypothesis : There are no cases of anorexia, hypothermia or hallucinations recorded in the Aes of the primary trial or the secondary trial.

Index 482 (Single, Intervention). Vrai : Contradiction. P1/P2 : Contradiction, FS : Entailment. Premise : INTERVENTION 1 : Bisphosphonate IV Q4W ; INTERVENTION 2 : Denosumab 180 mg Q12W. . .Hypothesis : The Interventions in the primary trial included different medications but are administered through the same routes.

Index 142 (Single, Intervention). Vrai : Entailment. P1/P2 : Entailment, FS : Contradiction. Premise : INTERVENTION 1 : SUNITINIB+CAPECITABINE, Sunitinib was administered orally from Day 1 at 37.5 mg/day on a continuous daily dosing schedule. . .Hypothesis : Sunitinib was administered orally every day, to every patient in the primary trial for the entire duration of the study.

Index 441 (Comparison, Adverse Events). Vrai : Entailment. P1/P2 : Entailment, FS : Contradiction. Premise : Diarrhea 7/30 (23.33%) ; Diarrhoea 0/6 (0.00%) ; Diarrhoea 0/6 (0.00%). Hypothesis : Diarrhoea was more common for the primary trial participants than the secondary trial participants.

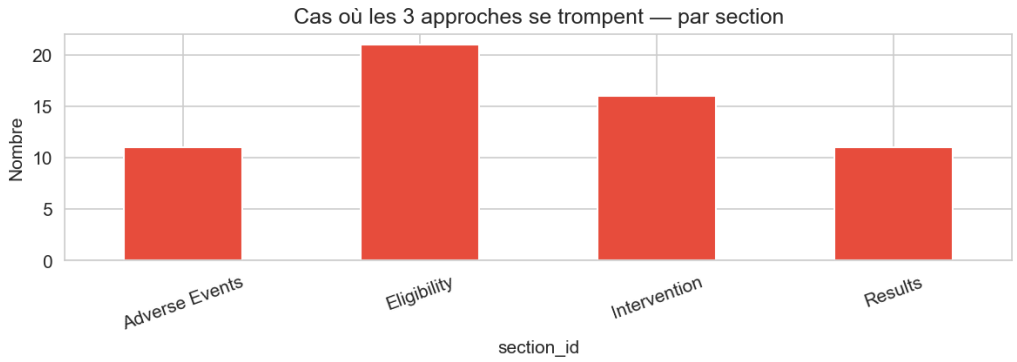

FIGURE 8 – Section 9 : répartition par section des 59 exemples où les 3 se trompent.

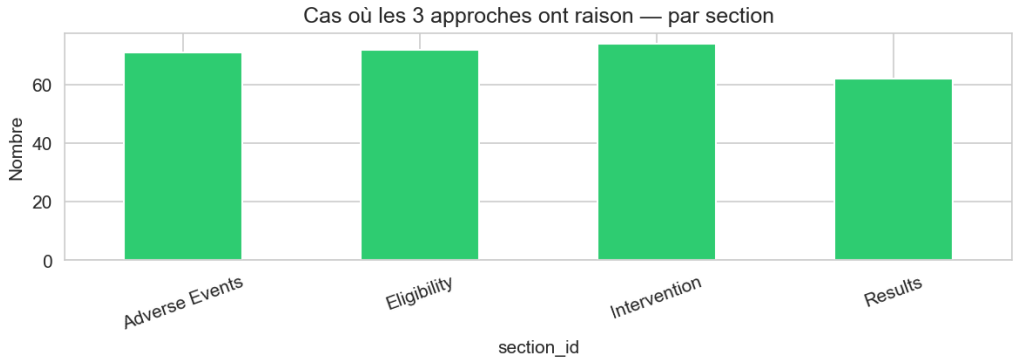

FIGURE 9 – Section 10 : répartition par section des 279 exemples où les 3 ont raison.

Les listes détaillées (index, type, section, labels) sont exportées en CSV : `compare_figures/three_approache` et utilisées pour l'analyse qualitative (exemples 5 par cas : 000, 001, 110) et la répartition par type/section dans la section 10b du notebook.

8 Matrices de confusion et erreurs

Les notebooks produisent des matrices de confusion (vrai label vs prédit) et des graphiques d'erreurs par section. Un point important ressort de ces matrices : la **baseline prédit majoritairement Contradiction**, alors que le **finetuning équilibre** les prédictions entre Entailment et Contradiction. Le modèle finetuné apprend ainsi à « prendre des risques » plutôt que de renvoyer systématiquement Contradiction par défaut. Figure de référence :

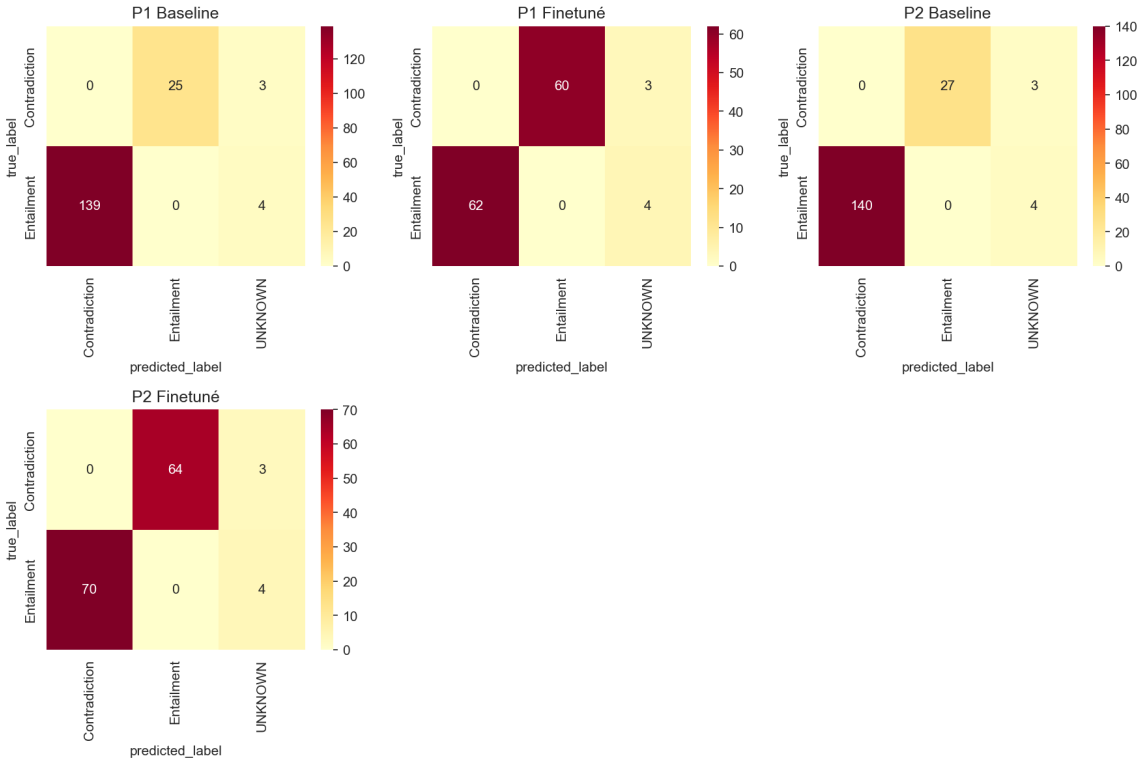

FIGURE 10 – Exemple de matrices de confusion (erreurs) — comparaison.

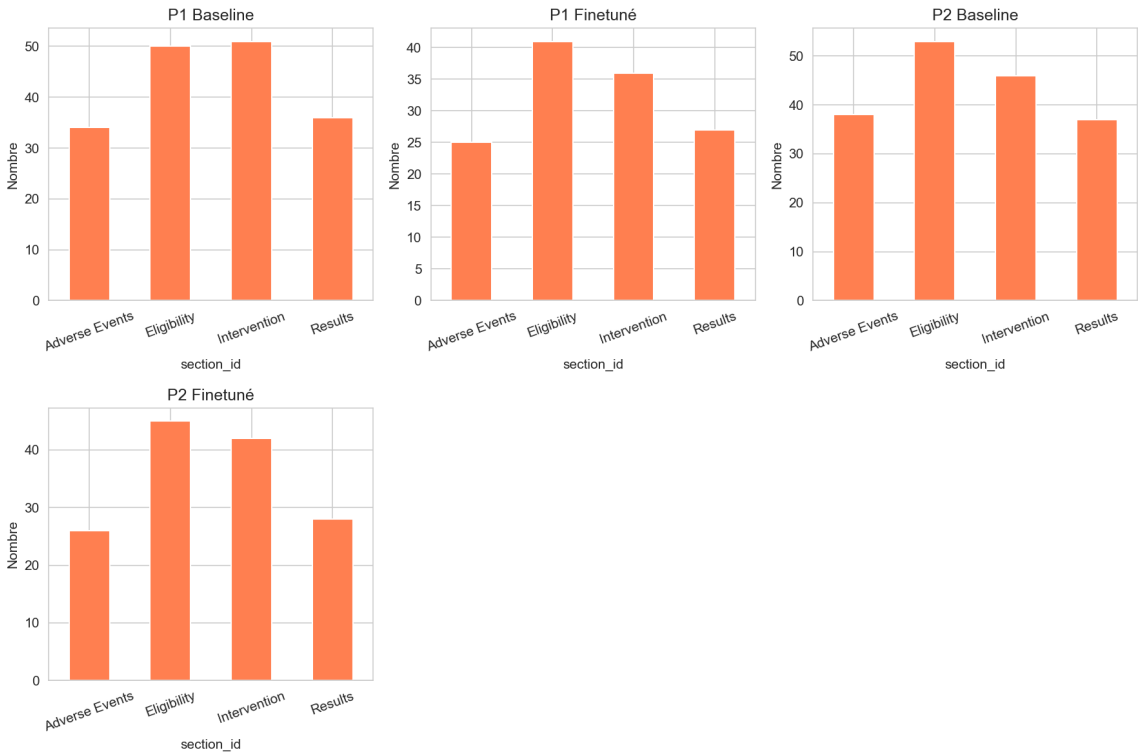

FIGURE 11 – Erreurs par section — comparaison.

9 Synthèse par approche

9.1 Prompt 1 (error_analysis_prompt1)

— Accord baseline et finetuné tous deux corrects : 269.
— Régressions : 60 ; Améliorations : 102.
— Bins longueur (finetuné) : Court 80,8%, Moyen 73,5%, Long 68,3%.

9.2 Prompt 2 (error_analysis_prompt2)

— Accord baseline et finetuné tous deux corrects : 266.
— Régressions : 60 ; Améliorations : 93.
— Bins longueur (finetuné) : Court 77,8%, Moyen 71,7%, Long 65,9%.

9.3 Few-shot Prompt 1 (error_analysis_fewshot_prompt1)

— Nombre de prédictions correctes : 360 / 500 (72%).
— Bins longueur : Court 77,8%, Moyen 66,3%, Long 71,9% (effet longueur moins monotone que pour le finetuning).

10 Conclusions

1. Le **finetuning** améliore nettement la baseline pour les deux prompts (P1 74,2%, P2 71,8%) et reste supérieur au few-shot (72%).
2. Les **matrices de confusion** montrent que la baseline prédit majoritairement Contradiction, alors que le finetuning équilibre les prédictions : le modèle finetuné apprend à « prendre des risques » et à prédire Entailment lorsque la prémisse supporte l'hypothèse, au lieu de renvoyer systématiquement Contradiction par défaut.

3. Les tâches **Comparison** sont plus difficiles que **Single** pour toutes les approches.
4. Les sections **Eligibility** et **Intervention** concentrent le plus d'erreurs ; **Adverse Events** et **Results** ont les meilleures accuracy.
5. Les **prompts longs** sont associés à plus d'erreurs pour le finetuning ; l'effet est moins marqué pour le few-shot.
6. Sur les patterns à trois (P1 FT, P2 FT, Few-shot) : 279 exemples où les 3 ont raison, 59 où les 3 se trompent ; 44 où seul le few-shot a raison (001) et 54 où seul le few-shot a tort (110). Une analyse qualitative (section 10b de `compare_error.ipynb`) et la répartition par type/section permettent d'interpréter ces cas.
7. Les exports (CSV, figures) sont dans `results/compare_figures/`, `results/Prompt 1/figures/`, `results/Prompt 2/figures/`, `results/Fewshot/figures/`.